

Machine Learning I

Dámaso Erling
20 de junio de 2025



Tipos de Aprendizaje

Tipo	Descripción	Ejemplos de algoritmos
Supervisado	Aprende con datos etiquetados.	Regresión lineal, SVM, Random Forest
No Supervisado	Encuentra patrones sin etiquetas.	K-Means, PCA, DBSCAN
Refuerzo	Aprende por ensayo y error para maximizar recompensas.	Q-Learning, DQN
Semi-supervisado	Usa pocos datos etiquetados.	Modelos híbridos
AutoML	Automatiza el diseño de modelos.	AutoSklearn, Google AutoML

Ejemplos de Aprendizaje Supervisado

Problema Salida (Y)	Tipo de Tarea	Entrada (X)
Predicción de precios de casas Precio de la casa	Regresión	Tamaño, cuartos, ubicación
Clasificación de correos Spam / No spam	Clasificación	Texto del correo
Diagnóstico médico Enfermo / Sano	Clasificación	Resultados clínicos
Reconocimiento de dígitos Número (0-9)	Clasificación	Imagen del dígito
Predicción de notas escolares Nota final	Regresión	Horas de estudio, asistencia
Clasificación de sentimientos Positivo / Negativo / Neutral	Clasificación	Comentario de usuario

Área	Aplicación destacada
Finanzas	Detección de fraude, scoring, trading
Salud	Diagnóstico, imagen médica, predicción
Marketing	Recomendaciones, segmentación, sentimiento
Tecnología	Asistentes, traducción, reconocimiento
Transporte	Rutas, mantenimiento, autos autónomos
Industria	Control de calidad, optimización de procesos

Tarea sugerida


- 1 Leer capítulo 1 de *Hands-On Machine Learning*.
- 2 Buscar 3 noticias actuales sobre aplicaciones ML.
- 3 Reflexión: “¿Qué problema cercano podría resolverse con ML?”

Resumen del Aprendizaje No Supervisado

El **aprendizaje no supervisado** consiste en analizar datos sin salidas etiquetadas, con el objetivo de identificar patrones o estructuras dentro de los datos.


A diferencia del **aprendizaje supervisado**, donde cada ejemplo tiene una etiqueta, el aprendizaje no supervisado requiere que el algoritmo descubra por sí mismo información relevante.

El **clustering** (agrupamiento) es un tipo común de aprendizaje no supervisado que agrupa datos no etiquetados en clústeres basados en similitudes.



- Un ejemplo es **Google News**, que utiliza clustering para agrupar artículos relacionados mediante palabras clave comunes, sin intervención humana.
- **Datos genéticos**: agrupa individuos según patrones de expresión génica, sin categorías predefinidas.
- **Segmentación de clientes**: las empresas agrupan a los consumidores en distintos mercados para personalizar productos y estrategias.

Metodologia CRISP-DM :CRoss-Industry Standard Process for Data Mining



1. Regresión Lineal: Simple vs Múltiple

Regresión Lineal Simple

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$$

$$e_i = y_i - \hat{y}_i$$

$$SSE = \sum e_i^2$$

Regresión Lineal Múltiple (matricial)

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

$$\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$$

$$\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}}$$

$$SSE = \mathbf{e}^\top \mathbf{e}$$

Función de Costo

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x_i) - y_i)^2$$

★ **Tarea:** Reproducir este modelo en Python y comparar resultados con Statsmodels.

Indicadores de Evaluación en Regresión Lineal

En un modelo de regresión lineal, se utilizan diversos indicadores estadísticos para evaluar su ajuste y precisión. A continuación, se describen los principales:

- **Coeficiente de determinación (R^2):**

$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}}$$

Donde SS_{res} es la suma de cuadrados de los residuos y SS_{tot} es la suma total de cuadrados. Mide la proporción de la varianza explicada por el modelo. Su valor está entre 0 y 1.

- **Coeficiente de determinación ajustado (R^2_{ajustado}):**

$$R^2_{\text{ajustado}} = 1 - \left(\frac{(1 - R^2)(n - 1)}{n - p - 1} \right)$$

Donde n es el número de observaciones y p el número de predictores. Corrige el R^2 por el número de variables independientes.

Indicadores de Evaluación en Regresión Lineal

- **Error cuadrático medio (MSE):**

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Representa la media de los errores al cuadrado entre los valores observados y los predichos.

- **Raíz del error cuadrático medio (RMSE):**

$$\text{RMSE} = \sqrt{\text{MSE}}$$

Mide el error promedio en las mismas unidades que la variable dependiente.

- **Error absoluto medio (MAE):**

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Mide la media de los errores absolutos entre las predicciones y los valores reales.

Indicadores de Evaluación en Regresión Lineal

- **Estadístico F:**

$$F = \frac{(SS_{\text{tot}} - SS_{\text{res}})/p}{SS_{\text{res}}/(n - p - 1)}$$

Evalúa si el modelo con predictores es significativamente mejor que un modelo sin predictores.

- **Prueba t para los coeficientes:**

$$t = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)}$$

Permite evaluar si cada coeficiente $\hat{\beta}_j$ es significativamente distinto de cero.

- **Intervalos de confianza para los coeficientes:**

$$\hat{\beta}_j \pm t_{\alpha/2, n-p-1} \cdot SE(\hat{\beta}_j)$$

Muestra el rango dentro del cual es probable que se encuentre el valor real del parámetro.

Supuestos de la Regresión Lineal

Para que los resultados de un modelo de regresión lineal sean válidos, se deben cumplir varios supuestos sobre los errores (ε):

- Normalidad de los errores
- Independencia de los errores (no autocorrelación)
- Homocedasticidad (varianza constante)

Resumen de Evaluación de Supuestos

Supuesto	Prueba	Resultado Esperado	Interpretación
Normalidad	Shapiro-Wilk / Q-Q	$p > 0,05$ / alineación	Residuos normales
Autocorrelación	Durbin-Watson	$DW \approx 2$	Errores independientes
Homocedasticidad	Breusch-Pagan / gráfico	$p > 0,05$ / sin patrón	Varianza constante

1. Normalidad de los errores

- **Gráfico Q-Q:** verifica alineación con la distribución normal.
- **Prueba de Shapiro-Wilk:**

H_0 : Los residuos son normales H_1 : Los residuos no son normales

- $p > 0,05 \Rightarrow$ No se rechaza la normalidad.

2. Autocorrelación de los errores

Estadístico de Durbin-Watson:

$$DW = \frac{\sum_{i=2}^n (e_i - e_{i-1})^2}{\sum_{i=1}^n e_i^2}$$

- $DW \approx 2 \Rightarrow$ No hay autocorrelación.
- $DW < 2 \Rightarrow$ Autocorrelación positiva.
- $DW > 2 \Rightarrow$ Autocorrelación negativa.

3. Homocedasticidad

- **Gráfico de residuos vs ajustados:** dispersión aleatoria indica homocedasticidad.
- **Prueba de Breusch-Pagan:**

H_0 : Varianza constante (homocedasticidad) H_1 : Varianza no constante

- $p > 0,05 \Rightarrow$ No se rechaza la homocedasticidad.

- La verificación de estos supuestos asegura la validez estadística del modelo.
- Los gráficos y pruebas estadísticas son herramientas complementarias.
- Su análisis debe formar parte de toda regresión seria.

Resumen: Gradiente Descendente para Regresión Lineal

Hipótesis:

$$h_{\theta}(x) = \theta_0 + \theta_1 x$$

Derivadas:

$$\frac{\partial J}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x_i) - y_i)$$

Costo:

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x_i) - y_i)^2 \quad \frac{\partial J}{\partial \theta_1} = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x_i) - y_i) x_i$$


Actualización:

$$\theta_j := \theta_j - \alpha \frac{\partial J}{\partial \theta_j}$$

- m : número de ejemplos
- y_i : valor real
- $h_{\theta}(x_i)$: predicción


- α : tasa de aprendizaje

Visualización del proceso



Convergencia hacia el mínimo de la función de costo.

Regresión Logística: Una Explicación Sencilla




La **regresión logística** es un método popular utilizado para clasificar datos en dos categorías, como determinar si un tumor es maligno (canceroso) o benigno (no canceroso).

En lugar de dar solo una **respuesta de sí o no**, la regresión logística proporciona una **puntuación de probabilidad entre 0 y 1**.

Por ejemplo, si el modelo predice una puntuación de 0.7 para un tumor, significa que hay un 70% de probabilidad de que el tumor sea maligno.

La Función Sigmoide



shutterstock.com - 2360153279

Para entender cómo funciona esto, pensemos en la **función sigmoide**, que es una curva especial que nos ayuda a hacer estas predicciones.

Imagina una **montaña rusa** que comienza abajo, sube lentamente y luego se nivela en la parte superior.

Esta curva nos ayuda a visualizar cómo cambia la probabilidad a medida que cambia la entrada (como el tamaño del tumor).

- Cuando la entrada es pequeña, la salida se acerca a 0.
- A medida que la entrada aumenta, la salida se acerca a 1.

Función de Costo en Regresión Logística

La función de costo utilizada es la **log-loss** o pérdida logística. Mide cuán bien el modelo predice las clases verdaderas.

Dada una muestra $(x^{(i)}, y^{(i)})$, la función de costo para un solo ejemplo es:

$$J(\theta) = - \left[y^{(i)} \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)})) \right]$$

Y para todo el conjunto de datos:

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)})) \right]$$

Donde:

- $h_{\theta}(x) = \frac{1}{1+e^{-\theta^T x}}$ es la función sigmoide
- m es el número de muestras
- $y^{(i)} \in \{0, 1\}$

Gradiente de la Función de Costo

Para minimizar la función de costo usamos **descenso del gradiente**. El gradiente con respecto a cada parámetro θ_j es:

$$\frac{\partial J(\theta)}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m \left(h_{\theta}(x^{(i)}) - y^{(i)} \right) x_j^{(i)}$$

Actualización de parámetros:

$$\theta_j := \theta_j - \alpha \frac{\partial J(\theta)}{\partial \theta_j}$$

Donde:

- α es la tasa de aprendizaje
- $x_j^{(i)}$ es la j -ésima característica del ejemplo i

¿Qué es una Matriz de Confusión?

Es una herramienta que permite visualizar el desempeño de un modelo de clasificación binaria.

Estructura:

	Predicho = 1	Predicho = 0
Real = 1	VP (Verdadero Positivo)	FN (Falso Negativo)
Real = 0	FP (Falso Positivo)	VN (Verdadero Negativo)

A partir de la matriz de confusión se calculan:

- **Exactitud** (Accuracy): $\frac{VP+VN}{VP+FP+FN+VN}$
- **Precisión** (Precision): $\frac{VP}{VP+FP}$
- **Sensibilidad / Recall**: $\frac{VP}{VP+FN}$
- **Especificidad**: $\frac{VN}{VN+FP}$
- **Valor F1**: $2 \cdot \frac{Precisión \cdot Recall}{Precisión + Recall}$
- **Tasa de Falsos Positivos (FPR)**: $\frac{FP}{FP+VN}$

¿Cómo interpretar estas métricas?

- **Precisión** alta: pocos falsos positivos.
- **Sensibilidad** alta: pocos falsos negativos.
- **Especificidad** alta: buen rechazo de la clase negativa.
- **F1-Score**: balance entre precisión y sensibilidad.
- **Exactitud**: útil si las clases están balanceadas.

La elección de la métrica clave depende del problema.

Código en Python

```
from sklearn.metrics import confusion_matrix

def metricas_matriz_confusion(y_verdadero, y_predicho):
    tn, fp, fn, tp = confusion_matrix(y_verdadero, y_predicho).ravel()

    exactitud      = (tp + tn) / (tp + tn + fp + fn)
    precision      = tp / (tp + fp)
    sensibilidad   = tp / (tp + fn)
    especificidad  = tn / (tn + fp)
    valor_f1       = 2 * (precision * sensibilidad) / (precision + sensibilidad)
    fpr            = fp / (fp + tn)

    print("Exactitud:", exactitud)
    print("Precisión:", precision)
    print("Sensibilidad:", sensibilidad)
    print("Especificidad:", especificidad)
    print("Valor F1:", valor_f1)
    print("Tasa de Falsos Positivos:", fpr)
```

- La matriz de confusión permite un diagnóstico profundo del modelo.
- Cada métrica responde a una necesidad específica.
- En modelos médicos, por ejemplo, la sensibilidad suele ser más crítica.

Evalúa tu modelo con más de una métrica.

1. **Identify the main components of the system.**


20 de junio de 2025

¿Qué es K-Means?

- Es un algoritmo de **aprendizaje no supervisado**.
- Sirve para agrupar datos en **K grupos** o clústeres.
- Cada grupo tiene un **centroide** que representa el centro del grupo.
- El objetivo es que los puntos dentro de un grupo sean similares entre sí.

Ejemplo sencillo

Supón que tienes los siguientes puntos en un plano:





Queremos agruparlos en 3 grupos ($K=3$). ¿Cómo hacerlo?

Pasos del algoritmo

- 1 Elegir aleatoriamente K puntos como **centroides iniciales**.
- 2 Asignar cada punto al centroide más cercano (formando los grupos).
- 3 Calcular el nuevo centroide de cada grupo.
- 4 Repetir los pasos 2 y 3 hasta que los centroides no cambien mucho.

Visualización de los pasos

- Inicialización:
- Agrupamiento:



¿Qué es un centroide?

- Es el **promedio** de todos los puntos dentro de un grupo.
- No tiene que ser un punto real del conjunto de datos.
- Es un punto que representa al grupo.

Distancias más usadas en K-Means

K-Means utiliza una medida de distancia para calcular qué tan lejos está un punto del centroide. Algunas de las más comunes son:

- **Distancia Euclidiana:**

- Fórmula: $\sqrt{\sum (x_i - y_i)^2}$
- Es la más usada en K-Means.
- Funciona bien cuando los datos están normalizados.

- **Distancia Manhattan (o de ciudad):**

- Fórmula: $\sum |x_i - y_i|$
- Útil cuando hay muchas dimensiones o los datos tienen forma de rejilla.

- **Distancia Coseno (para vectores):**

- Fórmula: $1 - \frac{x \cdot y}{\|x\| \|y\|}$
- Ideal cuando importa más la dirección que la magnitud, como en textos o imágenes.

- **Distancia de Mahalanobis (más avanzada):**

- Toma en cuenta the correlation between variables.
- Útil cuando las variables están correlacionadas y no siguen la misma escala.

¿Cómo elegir el valor de K?

- A veces se conoce K de antemano.
- Otras veces se prueba con diferentes valores.
- Se puede usar el método del **codo** (elbow method):
 - Se grafica la varianza intra-grupo vs. K.
 - El punto donde deja de bajar mucho es el mejor K.

¿Qué mide el Método del Codo?

El método del codo se utiliza para determinar el número óptimo de clusters k en el algoritmo de **K-Means**, evaluando la **inercia** del modelo.

Inercia: Suma de las distancias cuadradas de cada punto al centroide de su clúster:

$$\text{Inercia} = \sum_{i=1}^n \min_{\mu_j \in C} \|x_i - \mu_j\|^2$$

donde:

- x_i es el i -ésimo punto de datos,
- μ_j es el centroide del cluster j ,
- C es el conjunto de todos los centroides.

Se grafica la inercia frente a diferentes valores de k . El codo en la gráfica indica el punto óptimo donde añadir más clusters no mejora significativamente la agrupación.

Ventajas:

- Fácil de entender e implementar.
- Rápido y eficiente.
- Funciona bien con datos esféricos.

Desventajas:

- Necesita elegir K.
- Sensible a los valores iniciales.
- No funciona bien con clústeres de forma irregular.

¿Para qué sirve K-Means?

- Segmentación de clientes (marketing).
- Compresión de imágenes.
- Agrupación de documentos.
- Reconocimiento de patrones.

Ejemplo con scikit-learn

```
from sklearn.cluster import KMeans
import pandas as pd

# Supongamos que tenemos un DataFrame X con datos
kmeans = KMeans(n_clusters=3)
kmeans.fit(X)

# Etiquetas de grupo para cada punto
labels = kmeans.labels_
```

- K-Means agrupa datos en K clústeres.
- Usa distancias (Euclidiana, Manhattan, etc.) para asignar puntos al grupo más cercano.
- Es rápido, pero depende de la elección de K.
- Es muy útil para explorar y entender datos.